

Write-up (Kratak pregled izrade)

1. Šta je napravljeno, šta je izbačeno i da li je plan preživeo

U predviđenom vremenu u potpunosti je realizovan v1.0-core, koji je kompletan, produkciono funkcionalan sistem

Šta je napravljeno:

Arhitektura oslanja storage na S3, metapodatke i vektore na Postgres (sa pgvector ekstenzijom), a sinhronizaciju na lokalni Postgres red poslova sa custom worker-om. Umesto dodavanja kompleksnosti kroz LangChain, napisan je brz i čist ručni retrieve, prompt, generate pipeline. Autentifikacija je pokrivena preko dva seedovana korisnika, dok je fizička izolacija po tenantu ugrađena u samom startu.

Šta je izbačeno (odloženo):

Clerk autentifikacija, sporedni storage provajderi (Google Drive, Azure), least-privilege DB role, kao i napredne funkcije poput kompakcije konteksta i upravljanja istorijom chata.

Da li je plan preživeo susret sa kodom?

Za obavezni deo jeste. Dodatne celine (v1.1, v1.2) su u startu planirane po principu "samo ako ostane vremena". Kako je timebox potrošen na usaglašavanje konzistentnosti stanja dokumenata kroz ceo pipeline, ti tagovi su ostali čisto neizgrađeni umesto da uđu polovično urađeni.

2. Kako je rešena deduplikacija

Deduplikacija je rešena na nivou pojedinačnog korisnika korišćenjem SHA-256 heša sirovih bajtova (putanja, ime i vreme izmene se ignorišu).

- Brza provera (LIST poziv): Prilikom sync-a, worker izvršava samo brz LIST poziv nad S3 i poredi velicinu i ETag sa postojećim zapisima. Ako nema promena, fajl se odmah preskače, nula preuzimanja, nula ekstrakcije i nula embedding troška.

- Sadržajna deduplikacija: Ako je fajl nov ili izmenjen, skida se i hešuje. Ako taj content_hash već postoji u bazi tog tenanta, ekstrakcija i embedovanje se preskaču i koristi se postojeći sadržaj.

- Pametno čišćenje: Pri izmeni fajla na istoj putanji, stari sadržaj se briše samo ako nijedan drugi aktivan dokument tog korisnika više ne ukazuje na isti heš (refcount provera).

3. Kako se čuva izolacija dokumenata korisnika

Izolacija je primarno fizička na nivou baze (schema-per-tenant), a ne logički WHERE user_id = ... filter.

- Izolacija baze: Svaki korisnik ima sopstvenu Postgres šemu (tenant_<id>). Na osnovu verifikovanog JWT tokena, aplikativna sesija postavlja search_path za tu transakciju. Pošto tabele unutar tenant šeme uopšte nemaju user_id kolonu, ne postoji rizik od pogrešnog upita,

pokušaj pristupa tuđim podacima ne vraća prazan rezultat, već padne na nivou razrešavanja tabela.

- Storage izolacija: Kredencijali i podešavanja za S3 žive unutar izolovane šeme tenanta. Čak i kada dva različita korisnika sync-uju bajtno identičan fajl, njihovi vektori i sadržaji žive u odvojenim šemama i nikada se ne dele. Svesno je prihvaćen veći trošak embedovanja zarad apsolutne privatnosti.

- Trenutno ograničenje i sledeći korak: Worker i API trenutno koriste istu sistemsku konekciju ka bazi. Potpuno zatvaranje ove rupe uvođenjem posebne least-privilege DB role po tenantu je definisano kao prvi naredni korak (v1.1).

4. Šta dalje sa sledećih osam sati

Narednih osam sati rada pratilo bi tačno definisanu mapu tagova po redosledu prioriteta i vrednosti:

- v1.1 - Least-privilege DB rola po tenantu: Uvođenje zasebnih DB rola kako bi i eksplicitno kvalifikovani cross-schema upiti padali na nivou baze.

- v1.2 - Otpornost sync-a: Dodavanje heartbeat mehanizma i reaper procesa za prepoznavanje "mrtvih" worker-a, uz detaljnije praćenje parcijalnih grešaka po fajlu.

- v1.3 - Unapređenje chat sesija: Čuvanje istorije konverzacija u bazi uz automatsku sumaryzaciju starijih poruka radi uštede tokena.

- v1.4 - Google Drive provajder: Pisanje nove klase koja implementira postojeći Connector interfejs, čime se dodaje Drive bez izmena u sync worker-u.

- v1.5 - Clerk autentifikacija: Zamena seedovanih korisnika kompletnim produkcionim OAuth/JWT tokom.

- v1.6 & v1.7 - Kompakcija i kvalitet retrieval-a: Uvođenje hibridne pretrage (kombinacija BM25 i pgvector cosine sim) i reranking modela pred slanje konteksta LLM-u.